

STATISTICA INFERENZIALE

Scopo Ottenere info sulla distribuzione di una popolazione studiando dati rilevanti su un campione.

Statistica inferenziale La popolazione non è nota, prendo un campione e tramite l'analisi dico qualcosa sulla popolazione in modo INDUTTIVO.

Ipotesi chiave a) ogni nuova estrazione è indipendente dalle precedenti \rightarrow indipendenza
b) l'estrazione di ogni individuo che andrà a costruire il campione è fatta in modo identico al precedente \rightarrow equidistribuzione

Situazione (Ω, \mathcal{P}) spazio di probabilità su cui sono definite tutte le v.a. che considereremo.

- Il carattere che vogliamo studiare è rappresentato da una v.a. $X: \Omega \rightarrow \mathbb{R}$ con distribuzione P_X sconosciuta (in parte o totalmente);
- per determinare P_X , suppongo di avere da X_1, \dots, X_n v.a. i.i.d. che rappresentano il campione estratto.

Campione statistico Si intende di taglia n per X il dato di X_1, \dots, X_n con X_i v.a. i.i.d. con legge P_X .

es. altezza $\sim N(m, \sigma^2)$ mi aspetto che sia distribuita così ma non sono conosciuti i parametri. Cerco delle stime sui parametri tramite la STATISTICA PARAMETRICA.

Statistica parametrica Scopo:

- stime parametriche
- intervalli di fiducia
- test statistici

Notazione:

- β : indica un parametro non noto della popolazione;
- $\beta \in \mathcal{H}$: \mathcal{H} indica l'insieme dei valori ammissibili;
- P_X^β : la β indica che la prob. dipende da un parametro.

Statistica campionaria Funzione $g(X_1, \dots, X_n)$ del campione (X_1, \dots, X_n)

Stimatori di un parametro β Una statistica campionaria $P(X_1, \dots, X_n)$ atto a stimare β

es. Per stimare l'altezza di tutti gli iscritti alla triennale di informatica è $\bar{X}_{100} = \frac{X_1 + \dots + X_{100}}{100}$

Stimatore corretto
(non distorto)

Proposizione

$g(x_1, \dots, x_n)$ stimatore del parametro β si dice corretto se $E[g(x_1, \dots, x_n)] = \beta$

X_1, \dots, X_n campione statistico con momento secondo, allora:

- ① \bar{X}_n è uno stimatore corretto per $E[X_i] = E[X]$;
- ② S_n^2 è uno stimatore corretto per $\text{Var}(X_i) = \text{Var}(X)$

Dimostrazione:

- ① \bar{X}_n stimatore corretto per $E[X_i] \Leftrightarrow E[\bar{X}_n] = E[X]$
 $E[\frac{X_1 + \dots + X_n}{n}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \cdot n E[X] = E[X]$

- ② S_n^2 stimatore corretto per $\text{Var}(X) \Leftrightarrow E[S_n^2] = \text{Var}(X)$

DA FARZ DIH.

Stimatore Consistente

Parametro β della distribuzione, X_1, \dots, X_n $n \in \mathbb{N}$ campione di ∞ v.a. i.i.d. di X
 $g_n(x_1, \dots, x_n)$ è uno stimatore consistente di β se per $n \rightarrow \infty$ vale $g_n(x_1, \dots, x_n) \rightarrow \beta$ in probabilità

es. X_1, \dots, X_n campione di v.a. i.i.d. con momento secondo
Allora \bar{X}_n è uno stimatore consistente per $E[X_i] (= E[X] = \mu)$
e S_n^2 è uno stimatore consistente per $\text{Var}(X_i)$

Dim. si dimostra con LGN

Efficienza di uno stimatore

Presi $g(x_1, \dots, x_n)$ e $h(x_1, \dots, x_n)$ stimatori corretti del parametro β dico che g è più efficiente di h se $\text{Var}(g(x_1, \dots, x_n)) \leq \text{Var}(h(x_1, \dots, x_n))$

es. X_1, \dots, X_n v.a. i.i.d. $\Rightarrow \bar{X}_n$ è tanto più efficiente quanto più n aumenta

Dim. $\text{Var}(\bar{X}_n) = \text{Var}(\frac{X_1 + \dots + X_n}{n}) = \frac{1}{n^2} \cdot (\text{Var}(X_1) + \dots + \text{Var}(X_n)) = \frac{1}{n^2} \cdot n \text{Var}(X_i) = \frac{\text{Var}(X_i)}{n}$
quindi più cresce n e più diventa piccolo il risultato, si disperde meno

Metodo della massima verosimiglianza

Metodo per scegliere un buon stimatore. Ho (X_1, \dots, X_n) campione i.i.d di X , X con distribuzione P_X^β con β parametro.

Le v.a. possono essere:

- . discrete con funzione di massa $P_\beta(x)$
- . con densità $f_\beta(x)$

Funzione di verosimiglianza

$L_\beta: \mathbb{R}^n \rightarrow \mathbb{R}$ definita come:

- . caso discreto: $P_\beta(X_1, \dots, X_n) = P\{X_1 = x_1\} \cdot \dots \cdot P\{X_n = x_n\} = P\{X_1 = x_1, \dots, X_n = x_n\}$
- . caso con densità: $f_\beta(X_1) \cdot \dots \cdot f_\beta(X_n)$

Stima massima verosimiglianza (MLE)

Si chiama MLE se \exists una statistica campionaria $\hat{\beta} = \hat{\beta}(x_1, \dots, x_n)$ tale che valga l'uguaglianza $L_{\hat{\beta}}(x_1, \dots, x_n) = \max_{\beta \in H} L_\beta(x_1, \dots, x_n) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n$

Il massimo si trova tramite la derivata della funzione

Ho $y = L(\beta)$ e cerco $\frac{dL}{d\beta} = (\hat{\beta})$

Alle volte non basta una stima ma servono degli intervalli di fiducia

Intervalli di fiducia

(X_1, \dots, X_n) campione statistico di legge P_θ , $\theta \in H \subseteq \mathbb{R}$
 $\alpha \in (0, 1)$ e $a, b: \mathbb{R}^n \rightarrow \mathbb{R}$ funzioni t.c. $a(X_1, \dots, X_n), b(X_1, \dots, X_n)$ siano v.a.

Allora un intervallo aleatorio $I[a(X_1, \dots, X_n), b(X_1, \dots, X_n)]$ si dice intervallo di fiducia per θ di livello $1 - \alpha$ se

$$\forall \theta \in H \quad P_\theta(\theta \in I) = P(a(X_1, \dots, X_n) \leq \theta, b(X_1, \dots, X_n) \geq \theta) \geq 1 - \alpha$$

